

Examen de Teoría de Percepción  
ETSINF, Universitat Politècnica de València, Marzo de 2015

Apellidos:  Nombre:

Profesor: ☐ Carlos Martínez ☐ Roberto Paredes

**Cuestiones (3 puntos, 30 minutos, sin apuntes)**

- ☐ C Indicar la afirmación correcta respecto a la clasificación estadística:
- A) La regla óptima de clasificación es  $c(x) = \arg \max_{c=1 \dots C} p(\mathbf{x}|c)$
  - B) Se puede aplicar que  $P(c|\mathbf{x}) = P(c)p(\mathbf{x}|c)$
  - C) El clasificador basado en distancias puede verse como uno estadístico asumiendo  $P(c|\mathbf{x}) = \frac{k_c}{K}$
  - D) Sólo es aplicable cuando las probabilidades *a priori* son las mismas (equiprobables)
- ☐ D Se tienen las funciones discriminantes (para puntos en  $\mathbb{R}^2$ )  $g_1(\mathbf{x}) = 2x_1 - 2x_2 + 3$  y  $g_2(\mathbf{x}) = 3x_1 + x_2 - 2$ ; el punto (2,1) se clasificaría en:
- A) La clase 1
  - B) La clase 2
  - C) Ninguna de las clases, al no superar el umbral mínimo
  - D) En una clase al azar, al situarse en la frontera de decisión
- ☐ A Se tiene un problema de reconocimiento de imágenes, donde las imágenes son de  $20 \times 20$  píxeles a 256 niveles de gris, y se plantea su representación local usando ventanas de  $7 \times 7$ . ¿Qué afirmación es correcta?
- A) Con rejilla de un píxel, habrá un total de 196 ventanas
  - B) La representación local ocupará siempre más que la global
  - C) Con rejilla de un píxel, la representación local requiere más de 10000 bytes
  - D) Cada ventana requerirá más bytes que la representación global
- ☐ B Indicar cuál de las siguientes características *no* es propia del banco de filtros de Mel:
- A) Generalmente emplea filtros triangulares
  - B) Transforma la señal del dominio temporal al frecuencial
  - C) Imita la percepción humana, afinando para frecuencias bajas y siendo menos fino para las altas
  - D) Permite una reducción de dimensión de la representación frecuencial
- ☐ D Dada una colección de 50 documentos, de longitud máxima 65535 *tokens* sobre un conjunto de 220 *tokens* distintos, indicar cuánto ocuparía (aproximadamente) una representación (densa) de cuentas de bigramas de *tokens* para toda la colección:
- A) 21 Kbytes
  - B) 0.8 Mbytes
  - C) 2.3 Mbytes
  - D) 4.6 Mbytes
- ☐ A Dado un espacio de representación de  $d$  dimensiones se desea reducir a  $k$  dimensiones mediante PCA. Para ello se dispone de una matriz  $B_{n \times d}$  compuesta por los  $n$  vectores de entrenamiento, menos la media de dichos vectores, dispuestos en filas. Entonces:
- A) Escogeremos los  $k$  mayores eigenvectores (mayor eigenvalor asociado) de la matriz:  $\frac{1}{n} B^t B$
  - B) Escogeremos los  $k$  mayores eigenvectores (mayor eigenvalor asociado) de la matriz:  $\frac{1}{n} B B^t$
  - C) Escogeremos los  $k$  mayores eigenvectores (mayor eigenvalor asociado) de la matriz:  $\frac{1}{n} B$
  - D) Escogeremos los  $k$  mayores eigenvectores (mayor eigenvalor asociado) de la matriz:  $\frac{1}{n} B^t$

**D** Dado un problema de clasificación en 5 clases donde los objetos se representan en un espacio de 10 dimensiones. Se desea obtener una representación en un espacio reducido de 2 dimensiones. En general, ¿cuál de las siguientes reducciones es la menos aconsejable?

- A) Proyectar primero con PCA a 10 dimensiones y luego con LDA a 2
- B) Proyectar primero con PCA a 9 dimensiones y luego con LDA a 2
- C) Proyectar con LDA a 2 dimensiones y luego con PCA a 2
- D) Proyectar primero con PCA a 4 dimensiones y luego con LDA a 2

**D** Dado un problema de clasificación en  $C$  clases donde los objetos se representan en un espacio de  $d$  dimensiones, se desea obtener una representación en un espacio reducido de  $k$  dimensiones. Mediante PCA se obtiene  $W$  como matriz de proyección a  $d'$  dimensiones y a partir de los datos una vez proyectados mediante PCA se obtiene  $V$  como la matriz de proyección mediante LDA. Se debe de cumplir que:

- A)  $k \leq d'$  y  $d' \leq C - 1 \leq d$
- B)  $k \leq C - 1 \leq d' \leq d$
- C)  $k \leq d'$  y  $d' \leq d$
- D)  $k \leq C - 1$  y  $k \leq d' \leq d$

**B** Indica cuál de las siguientes afirmaciones es *falsa*

- A) El algoritmo Kernel Perceptron incrementa la importancia (peso) de las muestras incorrectamente clasificadas
- B) El uso de kernels es adecuado cuando los objetos son linealmente separables en el espacio de representación original
- C) El uso de kernels es adecuado cuando los objetos no son linealmente separables en el espacio de representación original
- D) Las funciones kernel modelan el producto escalar de dos vectores en un espacio de representación alternativo

**C** Sean  $K_1(\mathbf{x}, \mathbf{y})$  y  $K_2(\mathbf{x}, \mathbf{y})$  dos kernels, indica cuál de las siguientes expresiones *no* es un kernel

- A)  $(\mathbf{x}^t \mathbf{x}) \cdot K_1(\mathbf{x}, \mathbf{y}) \cdot (\mathbf{y}^t \mathbf{y})$
- B)  $\exp(K_1(\mathbf{x}, \mathbf{y}) + 1)$
- C)  $(c + K_1(\mathbf{x}, \mathbf{y}))^d \quad c, d \geq 0$
- D)  $K_1(\mathbf{x}, \mathbf{y}) + 2K_2(\mathbf{x}, \mathbf{y})$

Examen de Teoría de Percepción  
ETSINF, Universitat Politècnica de València, Marzo de 2015

Apellidos:  Nombre:

Profesor: ☐ Carlos Martínez ☐ Roberto Paredes

**Problemas (4 puntos, 90 minutos, con apuntes)**

1. (2 puntos) Se desea clasificar imágenes de  $4 \times 4$  píxeles representadas mediante representación directa con un vector de 16 dimensiones, recorriendo fila a fila. Las imágenes pertenecen a dos clases, clase 1 (aspas) y clase 2 (cuadrados). Las representación original es proyectada a 4 dimensiones mediante PCA, y en el espacio de 4 dimensiones se aplican funciones discriminantes lineales.

Los eigenvalores y eigenvectores de la matriz de covarianza de los datos son los siguientes:

$$\lambda = [1, 2, 2, 3, 3, 4, 4, 5, 6, 7, 7, 8, 9, 10, 11, 12]$$

$W =$

0	0	0	0	1	0	0	0	0	0	0	0	0	0	0	0
0	0	0	0	0	0	0	1	0	0	0	0	0	0	0	0
0	0	0	0	0	0	0	0	0	1	0	0	0	0	0	0
0	1	0	0	0	0	0	0	0	0	0	0	0	0	0	0
0	0	0	0	0	0	0	0	0	0	0	0	1	0	0	0
0	0	0	0	0	0	0	0	0	0	0	0	0	0	1	0
0	0	1	0	0	0	0	0	0	0	0	0	0	0	0	0
0	0	0	0	0	1	0	0	0	0	0	0	0	0	0	0
0	0	0	0	0	0	1	0	0	0	0	0	0	0	0	0
0	0	0	0	0	0	0	0	0	0	0	0	0	1	0	0
0	0	0	0	0	0	0	0	1	0	0	0	0	0	0	0
0	0	0	0	0	0	0	0	0	0	1	0	0	0	0	0
0	0	0	0	0	0	0	0	0	0	0	1	0	0	0	0
0	0	0	0	0	0	0	0	0	0	0	0	1	0	0	0
0	0	0	1	0	0	0	0	0	0	0	0	0	0	0	1
1	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0


Los eigenvalores estan en el vector  $\lambda$  y los eigenvectores asociados son las columnas de  $W$ .

Siendo las funciones discriminantes lineales :

$$g_1(\mathbf{x}) = \mathbf{w}_1 \mathbf{x} + b_1, \text{ con } \mathbf{w}_1 = [1, 0, 0, 1] \text{ y } b_1 = 0$$

$$g_2(\mathbf{x}) = \mathbf{w}_2 \mathbf{x} + b_2, \text{ con } \mathbf{w}_2 = [0, 1, 1, 0] \text{ y } b_2 = 1$$

- a) Proyecta la siguiente imagen a 4 dimensiones (con el menor error de reconstrucción posible) **Al no especificarse en el enunciado original, se supone que la media de los datos empleados para estimar la PCA es de 0. (1 punto)**



(Blanco=0, Negro=1)

- b) Clasifica el vector obtenido de acuerdo a las funciones discriminantes (1 punto)

**Solución:**

- a) Proyectar con las cuatro últimas columnas de  $W$ . La representación directa sería  $x = [0, 0, 0, 0, 0, 1, 1, 0, 0, 1, 1, 0, 0, 0, 0, 0]$ , y la proyección  $x' = [0, 1, 1, 0]$
- b)  $g_1(x') = 0$  y  $g_2(x') = 3$ , se clasificaría en la clase 2 (cuadrado)

2. (2 puntos) Dada la función kernel  $K(\mathbf{x}, \mathbf{y}) = (\mathbf{x} \cdot \mathbf{y} + 2)^2$  y el conjunto de aprendizaje en  $\mathbb{R}^3$   $X = \{(\mathbf{x}_1, -1), (\mathbf{x}_2, +1), (\mathbf{x}_3, -1), (\mathbf{x}_4, +1), (\mathbf{x}_5, +1)\}$ , siendo  $\mathbf{x}_1 = [0 \ 0 \ -1]$ ,  $\mathbf{x}_2 = [1 \ 0 \ 0]$ ,  $\mathbf{x}_3 = [0 \ 0 \ 1]$ ,  $\mathbf{x}_4 = [0 \ 1 \ 0]$ ,  $\mathbf{x}_5 = [0 \ -1 \ 0]$ , se pide:
- Obtener la matriz de kernel  $K$  asociada a  $X$  (0.5 puntos)
  - Realizar iteraciones hasta la convergencia del algoritmo Kernel Perceptron partiendo del conjunto de pesos  $\alpha = (1, 1, 1, 1, 1)$  (1 punto)
  - Clasificar la muestra  $\mathbf{y} = [-1 \ 0 \ 0]$  de acuerdo a los pesos obtenidos en el apartado previo (0.5 puntos)

**Solución:**

$$a) \ K = \begin{vmatrix} 9 & 4 & 1 & 4 & 4 \\ 4 & 9 & 4 & 4 & 4 \\ 1 & 4 & 9 & 4 & 4 \\ 4 & 4 & 4 & 9 & 1 \\ 4 & 4 & 4 & 1 & 9 \end{vmatrix}$$

- b)  $\mathbf{x}_1$ :  $g(\mathbf{x}_1) = 3$ ,  $c_1 g(\mathbf{x}_1) = -3 \leq 0$ ,  $\alpha_1 = 2$ ,  $\alpha = (2, 1, 1, 1, 1)$   
 $\mathbf{x}_2$ :  $g(\mathbf{x}_2) = 5$ ,  $c_2 g(\mathbf{x}_2) = 5 > 0$   
 $\mathbf{x}_3$ :  $g(\mathbf{x}_3) = 1$ ,  $c_3 g(\mathbf{x}_3) = -1 \leq 0$ ,  $\alpha_3 = 2$ ,  $\alpha = (2, 1, 2, 1, 1)$   
 $\mathbf{x}_4$ :  $g(\mathbf{x}_4) = -3$ ,  $c_4 g(\mathbf{x}_4) = -3 \leq 0$ ,  $\alpha_4 = 2$ ,  $\alpha = (2, 1, 2, 2, 1)$   
 $\mathbf{x}_5$ :  $g(\mathbf{x}_5) = -1$ ,  $c_5 g(\mathbf{x}_5) = -1 \leq 0$ ,  $\alpha_5 = 2$ ,  $\alpha = (2, 1, 2, 2, 2)$

$$\begin{aligned} \mathbf{x}_1: g(\mathbf{x}_1) &= 1, c_1 g(\mathbf{x}_1) = -1 \leq 0, \alpha_1 = 3, \alpha = (3, 1, 2, 2, 2) \\ \mathbf{x}_2: g(\mathbf{x}_2) &= 5, c_2 g(\mathbf{x}_2) = 5 > 0 \\ \mathbf{x}_3: g(\mathbf{x}_3) &= -1, c_3 g(\mathbf{x}_3) = 1 > 0 \\ \mathbf{x}_4: g(\mathbf{x}_4) &= 4, c_4 g(\mathbf{x}_4) = 4 > 0 \\ \mathbf{x}_5: g(\mathbf{x}_5) &= 4, c_5 g(\mathbf{x}_5) = 4 > 0 \end{aligned}$$

$$\mathbf{x}_1: g(\mathbf{x}_1) = -9, c_1 g(\mathbf{x}_1) = 9 > 0$$

- c)  $K(\mathbf{x}_1, \mathbf{y}) = 4$ ,  $K(\mathbf{x}_2, \mathbf{y}) = 1$ ,  $K(\mathbf{x}_3, \mathbf{y}) = 4$ ,  $K(\mathbf{x}_4, \mathbf{y}) = 4$ ,  $K(\mathbf{x}_5, \mathbf{y}) = 4$   
 Por tanto,  $g(y) = -3$ ,  $c(y) = -1$