

# Examen de Teoría de Percepción - Recuperación Segundo Parcial

ETSINF, Universitat Politècnica de València, Junio 2013

Apellidos:

Nombre:

Profesor: ☐ Carlos Martínez - Jorge Civera ☐ Roberto Paredes


## Cuestiones (3 puntos, 30 minutos, sin apuntes)

☐ C Los clasificadores basados en distancias

- A) aprenden las distribuciones de probabilidad sin tener que memorizar los prototipos
- B) requieren definir métricas
- C) son clasificadores basados en la similitud a ejemplos dados o prototipos
- D) inicialmente no requieren datos supervisados

☐ D La figura de la derecha muestra prototipos bidimensionales de 2 clases:  $x_0 = (4, 3, \bullet)$ ,  $x_1 = (3, 3, \circ)$ ,  $x_2 = (1, 3, \bullet)$ ,  $x_3 = (6, 3, \circ)$ ,  $x_4 = (3, 1, \bullet)$ ,  $x_5 = (4, 5, \circ)$ ,  $x_6 = (4, 0, \bullet)$ ,  $x_7 = (3, 6, \circ)$ ,  $x_8 = (5, 1, \bullet)$ ,  $x_9 = (2, 5, \circ)$ . ¿Cuántos prototipos se eliminan al aplicar el algoritmo de edición de Wilson por orden de índice utilizando los 3 vecinos más próximos en distancia Euclídea?

- A) 1
- B) 2
- C) 3
- D) 4



☐ B Se puede asegurar que la probabilidad de error del clasificador por los  $k$  vecinos más próximos siendo  $N$  el número de muestras de aprendizaje tiende al error de Bayes cuando:

- A)  $k > 1$  y  $N \rightarrow \infty$
- B)  $k = \log N$  y  $N \rightarrow \infty$
- C)  $N = \log k$  y  $k \rightarrow \infty$
- D)  $N > 1$  y  $k \rightarrow \infty$

☐ A El clasificador de Bernoulli se aplica a objetos representados mediante:

- A) Vectores de bits.
- B) Vectores de contadores (enteros no negativos) cuya suma es constante.
- C) Vectores de reales.
- D) Cadenas de símbolos.

☐ D ¿Cuál es el objetivo de las técnicas de suavizado?

- A) Evitar probabilidades nulas.
- B) Generalizar una distribución de probabilidad aprendida sobre una muestra.
- C) Mejorar la tasa de acierto de un clasificador.
- D) Todas las anteriores son correctas.

☐ C En una distribución gaussiana multidimensional, una matriz de covarianzas diagonal:

- A) es la única posibilidad.
- B) es una matriz de covarianzas incorrecta.
- C) indica que las componentes carecen de correlación lineal entre sí.
- D) indica que las componentes poseen una correlación lineal entre sí.

**A** Se recomienda emplear funciones kernel cuando:

- A) El espacio de representación original no es linealmente separable
- B) El kernel escogido modela el producto escalar en un nuevo espacio de representación
- C) El nuevo espacio de representación cabe en memoria
- D) El espacio de representación original es linealmente separable

**B** El kernel polinomial presenta la forma:

- A)  $K(\mathbf{x}, \mathbf{y}) = (\mathbf{x} + \mathbf{y})^d$
- B)  $K(\mathbf{x}, \mathbf{y}) = (\mathbf{x} \cdot \mathbf{y} + c)^d$
- C)  $K(\mathbf{x}, \mathbf{y}) = (\mathbf{x} \cdot \mathbf{y}) + c^d$
- D)  $K(\mathbf{x}, \mathbf{y}) = (\mathbf{x}^d + \mathbf{y}^c)$

**D** La realimentación no determinista suele modelarse a partir del modelo estadístico:

- A)  $\hat{h} \approx \arg \max_h P(f|d)P(d|h')P(x|h)P(h|h', d)$
- B)  $(\hat{h}, \hat{d}) \approx \arg \max_{h,d} P(d|h')P(x|h)$
- C)  $(\hat{h}, \hat{d}) \approx \arg \max_{h,d} P(f|d)P(x|h)$
- D)  $(\hat{h}, \hat{d}) \approx \arg \max_{h,d} P(f|d)P(d|h')P(x|h)P(h|h', d)$

**A** La medida de la calidad de los sistemas interactivos se basa en:

- A) el esfuerzo del operador humano.
- B) el tiempo de cómputo del aprendizaje adaptativo.
- C) la tasa de error final del sistema.
- D) el número de acciones de supervisión propuesto por el sistema, sin tener en cuenta las correcciones del operador.

# Examen de Teoría de Percepción - Recuperación Segundo Parcial

ETSINF, Universitat Politècnica de València, Junio 2013


Apellidos:

Nombre:

Profesor: ☐ Carlos Martínez - Jorge Civera ☐ Roberto Paredes

## Problemas (4 puntos, 90 minutos, con apuntes)

1. (1 punto) Dado el conjunto de aprendizaje  $X = \{\mathbf{x}_1, \mathbf{x}_2, \mathbf{x}_3, \mathbf{x}_4, \mathbf{x}_5, \mathbf{x}_6, \mathbf{x}_7\}$  con la distribución de clases que muestra la figura. Realiza una ejecución del algoritmo de condensado de Hart.



Clase A

$\mathbf{x}_1 = (1, 1)$

$\mathbf{x}_3 = (1, 3)$

$\mathbf{x}_5 = (3, 4)$

Clase B

$\mathbf{x}_2 = (3, 1)$

$\mathbf{x}_4 = (4, 2)$

$\mathbf{x}_6 = (3, 2)$

$\mathbf{x}_7 = (5, 4)$

El orden de recorrido de los prototipos en el algoritmo de Hart es el del índice de los mismo:  $\mathbf{x}_1 \dots \mathbf{x}_7$

### Solución:

Primera parte, construcción del conjunto  $S$  y  $G$ :

$\mathbf{x}_1 \rightarrow S$

$\mathbf{x}_2$ , Error  $\rightarrow S$

$\mathbf{x}_3$ , Acierto  $\rightarrow G$

$\mathbf{x}_4$ , Acierto  $\rightarrow G$

$\mathbf{x}_5$ , Error  $\rightarrow S$

$\mathbf{x}_6$ , Acierto  $\rightarrow G$

$\mathbf{x}_7$ , Error  $\rightarrow S$

$S = \{\mathbf{x}_1, \mathbf{x}_2, \mathbf{x}_5, \mathbf{x}_7\}$  y  $G = \{\mathbf{x}_3, \mathbf{x}_4, \mathbf{x}_6\}$

Segunda parte, recorrido de  $G$ :

$\mathbf{x}_3$ , Acierto, no mover a  $S$

$\mathbf{x}_4$ , Acierto, no mover a  $S$

$\mathbf{x}_6$ , Acierto, no mover a  $S$

$error = 0 \rightarrow$  Acabar

Acaba con el conjunto reducido:  $S = \{\mathbf{x}_1, \mathbf{x}_2, \mathbf{x}_5, \mathbf{x}_7\}$

2. (1 punto) Tenemos  $N = 12$  vectores binarios tridimensionales aleatoriamente extraídas de  $C = 3$  distros Bernoulli independientes:

$n$	1	2	3	4	5	6	7	8	9	10	11	12
$x_{n1}$	1	1	1	1	0	0	0	0	0	1	1	0
$x_{n2}$	0	0	0	0	1	1	0	1	1	1	1	1
$x_{n3}$	1	0	1	0	1	1	1	1	0	0	0	0
$c_n$	1	1	1	1	2	2	2	2	3	3	3	3

- a) Estima todos los parámetros del clasificador Bernoulli más probable.  
b) Suaviza los prototipos Bernoulli con truncamiento simple ( $\epsilon = 1/8$ ) y clasifica la muestra  $y = (0 \ 0 \ 1)$ .

**Solución:**

a)

$$p(1) = p(2) = p(3) = \frac{1}{3}$$

$$\hat{\mathbf{p}}_1 = \frac{1}{4} \begin{pmatrix} 1+1+1+1 \\ 0+0+0+0 \\ 1+0+1+0 \end{pmatrix} = \begin{pmatrix} 1 \\ 0 \\ 1/2 \end{pmatrix}$$

$$\hat{\mathbf{p}}_2 = \frac{1}{4} \begin{pmatrix} 0+0+0+0 \\ 1+1+0+1 \\ 1+1+1+1 \end{pmatrix} = \begin{pmatrix} 0 \\ 3/4 \\ 1 \end{pmatrix}$$

$$\hat{\mathbf{p}}_3 = \frac{1}{4} \begin{pmatrix} 0+1+1+0 \\ 1+1+1+1 \\ 0+0+0+0 \end{pmatrix} = \begin{pmatrix} 1/2 \\ 1 \\ 0 \end{pmatrix}$$

b)

$$\hat{\mathbf{p}}_1 = \begin{pmatrix} 1 \\ 0 \\ 1/2 \end{pmatrix} \rightarrow \hat{\mathbf{p}}_1 = \begin{pmatrix} 7/8 \\ 1/8 \\ 1/2 \end{pmatrix}$$

$$\hat{\mathbf{p}}_2 = \begin{pmatrix} 0 \\ 3/4 \\ 1 \end{pmatrix} \rightarrow \hat{\mathbf{p}}_2 = \begin{pmatrix} 1/8 \\ 3/4 \\ 7/8 \end{pmatrix}$$

$$\hat{\mathbf{p}}_3 = \begin{pmatrix} 1/2 \\ 1 \\ 0 \end{pmatrix} \rightarrow \hat{\mathbf{p}}_3 = \begin{pmatrix} 1/2 \\ 7/8 \\ 1/8 \end{pmatrix}$$

En nuestro caso, dado que las priors son idénticas, la regla de clasificación se reduce a:  $\hat{c}(y) = \arg \max_c p(y | c)$

$$p(y = (0 \ 0 \ 1) | c = 1) = (7/8)^0 (1 - 7/8)^{(1-0)} (1/8)^0 (1 - 1/8)^{(1-0)} (1/2)^1 (1 - 1/2)^{(1-1)} = 1/8 \cdot 7/8 \cdot 1/2 = \frac{7}{128}$$

$$p(y = (0 \ 0 \ 1) | c = 2) = (1/8)^0 (1 - 1/8)^{(1-0)} (3/4)^0 (1 - 3/4)^{(1-0)} (7/8)^1 (1 - 7/8)^{(1-1)} = 7/8 \cdot 1/4 \cdot 7/8 = \frac{49}{256}$$

$$p(y = (0 \ 0 \ 1) | c = 3) = (1/2)^0 (1 - 1/2)^{(1-0)} (7/8)^0 (1 - 7/8)^{(1-0)} (1/8)^1 (1 - 1/8)^{(1-1)} = 1/2 \cdot 1/8 \cdot 1/8 = \frac{1}{128}$$

La muestra  $y$  se clasifica en la clase 2.

3. (1 punto) Se definen las clases  $A$  y  $B$  en un espacio bidimensional; cada clase está modelada respectivamente por una gaussiana, de forma que sus parámetros son:

$$\mu_A = \begin{pmatrix} 1 & 1 \end{pmatrix}^t \quad \Sigma_A = \begin{pmatrix} 1 & 0 \\ 0 & 2 \end{pmatrix}$$

$$\mu_B = \begin{pmatrix} 0 & -1 \end{pmatrix}^t \quad \Sigma_B = \begin{pmatrix} 3 & 0 \\ 0 & 1 \end{pmatrix}$$

Sabiendo que las probabilidades *a priori* de cada clase son  $P(A) = 0.4$  y  $P(B) = 0.6$ , clasifica la muestra  $\mathbf{x} = \begin{pmatrix} 1 & -1 \end{pmatrix}^t$ .

**Solución:**

Usando clasificación por máxima verosimilitud y regla de Bayes, el problema se reduce a calcular

$$c^* = \arg \max_{c \in \{A, B\}} P(c)p(x|c)$$

Por tanto:

$$p(x|A) = \frac{1}{|\Sigma_A|^{\frac{1}{2}} 2\pi} \cdot e^{-\frac{1}{2}(\mathbf{x}-\mu_A)^t \Sigma_A^{-1}(\mathbf{x}-\mu_A)} = \frac{1}{2\sqrt{2}\pi} \cdot e^{-\frac{1}{2} \begin{pmatrix} 0 & -2 \end{pmatrix} \begin{pmatrix} 1 & 0 \\ 0 & \frac{1}{2} \end{pmatrix} \begin{pmatrix} 0 \\ -2 \end{pmatrix}} = \frac{1}{2\sqrt{2}\pi} \cdot e^{-1}$$

$$p(x|B) = \frac{1}{|\Sigma_B|^{\frac{1}{2}} 2\pi} \cdot e^{-\frac{1}{2}(\mathbf{x}-\mu_B)^t \Sigma_B^{-1}(\mathbf{x}-\mu_B)} = \frac{1}{2\sqrt{3}\pi} \cdot e^{-\frac{1}{2} \begin{pmatrix} 1 & 0 \end{pmatrix} \begin{pmatrix} \frac{1}{3} & 0 \\ 0 & 1 \end{pmatrix} \begin{pmatrix} 1 \\ 0 \end{pmatrix}} = \frac{1}{2\sqrt{3}\pi} \cdot e^{-\frac{1}{6}}$$

$$P(A|x) = P(A)p(x|A) = 0.4 \cdot \frac{1}{2\sqrt{2}\pi} \cdot e^{-1} \approx 0.0166$$

$$P(B|x) = P(B)p(x|B) = 0.6 \cdot \frac{1}{2\sqrt{3}\pi} \cdot e^{-\frac{1}{6}} \approx 0.0467$$

Por tanto, se clasifica en la clase **B**.

4. (1 punto) Tenemos la muestra de entrenamiento  $X = \{(\mathbf{x}_1, +1), (\mathbf{x}_2, -1), (\mathbf{x}_3, +1), (\mathbf{x}_4, -1)\}$ , y la matriz de kernel:

$$K = \begin{pmatrix} 1 & \frac{1}{2} & \frac{1}{3} & \frac{2}{3} \\ \frac{1}{2} & 1 & \frac{1}{2} & \frac{1}{3} \\ \frac{1}{3} & \frac{1}{2} & 1 & \frac{1}{3} \\ \frac{2}{3} & \frac{1}{3} & \frac{1}{3} & 1 \end{pmatrix}$$

Obtén el valor de las  $\alpha_i$  que daría el algoritmo Kernel-Perceptrón para este conjunto de datos.

**Solución:**

Partimos de  $\alpha = \{0, 0, 0, 0\}$ , usando la función a optimizar  $g(\mathbf{x}) = \sum_{i=1}^4 \alpha_i \cdot c_i \cdot K(\mathbf{x}, \mathbf{x}_i) + \sum_{i=1}^4 \alpha_i \cdot c_i$ .

**1ª iteración**

- $g(\mathbf{x}_1) = 0 \rightarrow c_1 g(\mathbf{x}_1) = 0 \leq 0 \rightarrow \alpha_1 = 1 \rightarrow \alpha = \{1, 0, 0, 0\}$
- $g(\mathbf{x}_2) = K(\mathbf{x}_2, \mathbf{x}_1) + \alpha_1 = \frac{1}{2} + 1 = \frac{3}{2} \rightarrow c_2 g(\mathbf{x}_2) = -\frac{3}{2} \leq 0 \rightarrow \alpha_2 = 1 \rightarrow \alpha = \{1, 1, 0, 0\}$
- $g(\mathbf{x}_3) = K(\mathbf{x}_3, \mathbf{x}_1) - K(\mathbf{x}_3, \mathbf{x}_2) + \alpha_1 - \alpha_2 = \frac{1}{3} - \frac{1}{2} + 1 - 1 = -\frac{1}{6} \rightarrow c_3 g(\mathbf{x}_3) = -\frac{1}{6} \leq 0 \rightarrow \alpha_3 = 1 \rightarrow \alpha = \{1, 1, 1, 0\}$
- $g(\mathbf{x}_4) = K(\mathbf{x}_4, \mathbf{x}_1) - K(\mathbf{x}_4, \mathbf{x}_2) + K(\mathbf{x}_4, \mathbf{x}_3) + \alpha_1 - \alpha_2 + \alpha_3 = \frac{2}{3} - \frac{1}{3} + \frac{1}{3} + 1 - 1 + 1 = \frac{5}{3} \rightarrow c_4 g(\mathbf{x}_4) = -\frac{5}{3} \leq 0 \rightarrow \alpha_4 = 1 \rightarrow \alpha = \{1, 1, 1, 1\}$

**2ª iteración**

- $g(\mathbf{x}_1) = K(\mathbf{x}_1, \mathbf{x}_1) - K(\mathbf{x}_1, \mathbf{x}_2) + K(\mathbf{x}_1, \mathbf{x}_3) - K(\mathbf{x}_1, \mathbf{x}_4) + \alpha_1 - \alpha_2 + \alpha_3 - \alpha_4 = 1 - \frac{1}{2} + \frac{1}{3} - \frac{2}{3} + 1 - 1 + 1 - 1 = \frac{1}{6} \rightarrow c_1 g(\mathbf{x}_1) = \frac{1}{6} > 0 \rightarrow \alpha = \{1, 1, 1, 1\}$
- $g(\mathbf{x}_2) = K(\mathbf{x}_2, \mathbf{x}_1) - K(\mathbf{x}_2, \mathbf{x}_2) + K(\mathbf{x}_2, \mathbf{x}_3) - K(\mathbf{x}_2, \mathbf{x}_4) + \alpha_1 - \alpha_2 + \alpha_3 - \alpha_4 = \frac{1}{2} - 1 + \frac{1}{2} - \frac{1}{3} + 1 - 1 + 1 - 1 = -\frac{1}{3} \rightarrow c_2 g(\mathbf{x}_2) = \frac{1}{3} > 0 \rightarrow \alpha = \{1, 1, 1, 1\}$
- $g(\mathbf{x}_3) = K(\mathbf{x}_3, \mathbf{x}_1) - K(\mathbf{x}_3, \mathbf{x}_2) + K(\mathbf{x}_3, \mathbf{x}_3) - K(\mathbf{x}_3, \mathbf{x}_4) + \alpha_1 - \alpha_2 + \alpha_3 - \alpha_4 = \frac{1}{3} - \frac{1}{2} + 1 - \frac{1}{3} + 1 - 1 + 1 - 1 = \frac{1}{2} \rightarrow c_3 g(\mathbf{x}_3) = \frac{1}{2} > 0 \rightarrow \alpha = \{1, 1, 1, 1\}$
- $g(\mathbf{x}_4) = K(\mathbf{x}_4, \mathbf{x}_1) - K(\mathbf{x}_4, \mathbf{x}_2) + K(\mathbf{x}_4, \mathbf{x}_3) - K(\mathbf{x}_4, \mathbf{x}_4) + \alpha_1 - \alpha_2 + \alpha_3 - \alpha_4 = \frac{2}{3} - \frac{1}{3} + \frac{1}{3} - 1 + 1 - 1 + 1 - 1 = -\frac{1}{3} \rightarrow c_4 g(\mathbf{x}_4) = \frac{1}{3} > 0 \rightarrow \alpha = \{1, 1, 1, 1\}$

Al no haber cambios en esta segunda iteración, se tiene finalmente que  $\alpha = \{1, 1, 1, 1\}$ .