

Examen de Teoría de Percepción - Segundo Parcial

ETSINF, Universitat Politècnica de València, Junio de 2013

Apellidos:

Nombre:

Profesor: ☐ Carlos Martínez - Jorge Civera ☐ Roberto Paredes

Cuestiones (3 puntos, 30 minutos, sin apuntes)

A Dada una representación vectorial de los objetos, ¿Cuál de las siguientes distancias **no** es una métrica?


- A) $d(x, y) = \sum_{i=1}^d (x_i - y_i)$.
- B) $d(x, y) = \sum_{i=1}^d |x_i - y_i|$.
- C) $d(x, y) = \sum_{i=1}^d (x_i - y_i)^2$.
- D) $d(x, y) = (\sum_{i=1}^d |x_i - y_i|^3)^{1/3}$.

D Dado un conjunto de datos de tamaño n , al calcular los K -vecinos más cercanos de \mathbf{x} se obtienen k_c vecinos de la clase c , y esto permite:

- A) una estimación directa de $p(\mathbf{x}|c)$, con $p(\mathbf{x}|c) = \frac{k_c}{n}$.
- B) una estimación directa de $p(\mathbf{x}|c)$, con $p(\mathbf{x}|c) = \frac{k_c}{K}$.
- C) una estimación directa de $p(c|\mathbf{x})$, con $p(c|\mathbf{x}) = \frac{k_c}{n}$.
- D) una estimación directa de $p(c|\mathbf{x})$, con $p(c|\mathbf{x}) = \frac{k_c}{K}$.

D La figura de la derecha muestra prototipos bidimensionales de 2 clases: \circ y \bullet . Estima el error del clasificador por el vecino más próximo (en distancia Euclídea) considerando como conjunto de entrenamiento $\{(2, 6), (3, 4), (4, 2)\}$ y conjunto de test $\{(4, 4), (5, 1), (5, 5)\}$.

- A) 0
- B) $1/3$
- C) $1/2$
- D) $2/3$



D Considérese la probabilidad de error asintótica del clasificador por los k vecinos más próximos; esto es, su probabilidad de error cuando el número n de prototipos sobre los que se basa tiende a infinito. ¿Cuál de las siguientes condiciones sobre k es suficiente para garantizar la convergencia de esta probabilidad de error a la del clasificador de Bayes?

- A) $k > 2$
- B) $k = \frac{N}{10}$
- C) $k = 2N$
- D) Ninguna de las anteriores.

B Dado el siguiente conjunto de vectores binarios bidimensionales:

n	1	2	3	4	5	6	7	8	9	10	11	12
x_{n1}	1	0	0	1	1	1	1	1	0	0	0	1
x_{n2}	0	0	1	0	0	0	1	0	0	0	0	1
c_n	1	1	1	1	1	1	2	2	2	2	2	2

¿Cuál es la estimación de los parámetros del clasificador Bernoulli más probable?

- A) $\hat{p}(1) = \hat{p}(2) = \frac{1}{4}$, $\hat{\mathbf{p}}_1 = \left(\frac{1}{4}, \frac{1}{12}\right)^t$ y $\hat{\mathbf{p}}_2 = \left(\frac{1}{4}, \frac{1}{6}\right)^t$
- B) $\hat{p}(1) = \hat{p}(2) = \frac{1}{2}$, $\hat{\mathbf{p}}_1 = \left(\frac{2}{3}, \frac{1}{6}\right)^t$ y $\hat{\mathbf{p}}_2 = \left(\frac{1}{2}, \frac{1}{3}\right)^t$
- C) $\hat{p}(1) = \hat{p}(2) = \frac{1}{4}$, $\hat{\mathbf{p}}_1 = \left(\frac{2}{3}, \frac{1}{6}\right)^t$ y $\hat{\mathbf{p}}_2 = \left(\frac{1}{2}, \frac{1}{3}\right)^t$
- D) $\hat{p}(1) = \hat{p}(2) = \frac{1}{2}$, $\hat{\mathbf{p}}_1 = \left(\frac{1}{4}, \frac{1}{12}\right)^t$ y $\hat{\mathbf{p}}_2 = \left(\frac{1}{4}, \frac{1}{6}\right)^t$

B *Laplace* es una técnica de suavizado de parámetros que aplicamos al:

- A) Clasificador de Bernoulli.
- B) Clasificador multinomial.
- C) Clasificador Gaussiano.
- D) Ninguno de los anteriores.

A Con respecto a los modelos de mixturas de gaussianas (GMM)

- A) La estimación de sus parámetros requiere de procesos iterativos como el basado en el algoritmo EM.
- B) La estimación de sus parámetros se hace de forma directa sin proceso iterativo.
- C) Son modelos que no reflejan una distribución de probabilidad correcta.
- D) Sus parámetros estimables son las medias y las varianzas de cada gaussiana, pero no los pesos asociados

B El uso de kernels es adecuado cuando:

- A) Los objetos son linealmente separables en el espacio de representación escogido.
- B) Los objetos no son linealmente separables en el espacio de representación escogido.
- C) Queremos proyectar los datos a un espacio de menor dimensionalidad linealmente separable.
- D) Queremos garantizar que los datos quedan linealmente separables para cualquier kernel.

C Esencialmente el algoritmo Kernel Perceptron lo que hace es:

- A) Incrementar la importacia (peso) de las muestras correctamente clasificadas.
- B) Decrementar la importacia (peso) de las muestras correctamente clasificadas.
- C) Incrementar la importacia (peso) de las muestras incorrectamente clasificadas.
- D) Decrementar la importacia (peso) de las muestras incorrectamente clasificadas.

C El protocolo de interacción izquierda-derecha

- A) Es un protocolo exclusivamente activo
- B) Es un protocolo sólo aplicable en sistemas adaptativos
- C) Es el protocolo más apropiado ante entradas secuenciales
- D) Es un protocolo que no requiere de entrada

Examen de Teoría de Percepción - Segundo Parcial

ETSINF, Universitat Politècnica de València, Junio de 2013

Apellidos:

Nombre:


Profesor: ☐ Carlos Martínez - Jorge Civera ☐ Roberto Paredes

Problemas (4 puntos, 90 minutos, con apuntes)

1. (1 punto) La figura de la derecha muestra prototipos bidimensionales de 2 clases:
 $x_1 = (1, 2, \circ)$, $x_2 = (2, 1, \bullet)$, $x_3 = (3, 2, \circ)$, $x_4 = (2, 4, \bullet)$, $x_5 = (5, 2, \circ)$, $x_6 = (2, 5, \bullet)$.
 Aplica el algoritmo de edición de Wilson sobre el conjunto de prototipos por orden de índice utilizando vecino más próximo ($k = 1$) en distancia:

- a) Euclídea.
 b) Mahalanobis-diagonal por clase.

Nota: Si es necesario, asume que $\infty \cdot 0 = 0$.



Solución:

- a) El algoritmo de Wilson se reduce a recorrer iterativamente los prototipos tomando uno de ellos como muestra de test y el resto como muestras de entrenamiento, eliminando los prototipos mal clasificados. En este caso es el clasificador de vecino más próximo ($k = 1$) con distancia Euclídea convencional:

	Clase estimada	Conjunto resultante
$x_1 = (1, 2, \circ)$	\bullet	$\{x_2, x_3, x_4, x_5, x_6\}$
$x_2 = (2, 1, \bullet)$	\circ	$\{x_3, x_4, x_5, x_6\}$
$x_3 = (3, 2, \circ)$	\circ	$\{x_3, x_4, x_5, x_6\}$
$x_4 = (2, 4, \bullet)$	\bullet	$\{x_3, x_4, x_5, x_6\}$
$x_5 = (5, 2, \circ)$	\circ	$\{x_3, x_4, x_5, x_6\}$
$x_6 = (2, 5, \bullet)$	\bullet	$\{x_3, x_4, x_5, x_6\}$

- b) En este caso el algoritmo de Wilson utiliza el clasificador de vecino más próximo ($k = 1$) con distancia Mahalanobis-diagonal por clase:

$$d(\mathbf{y}, \mathbf{p}) = \sqrt{\sum_{i=1}^D \frac{1}{\sigma_{ic}^2} (y_i - p_i)^2}$$

donde c es la clase de \mathbf{p} , y σ_{ic}^2 es la varianza de la componente i -ésima en la clase c .

Aplicamos una primera iteración del algoritmo de Wilson. Para calcular la distancia de Mahalanobis-diagonal por clase entre cada prototipo \mathbf{p} y un prototipo excluido \mathbf{y} , necesitamos calcular previamente las varianzas por clase y componente que en todos los casos son:

σ_{ic}^2	$i = 1$	$i = 2$
$c = \circ$	$\alpha > 0$	0
$c = \bullet$	0	$\beta > 0$

La distancia entre un prototipo \mathbf{p} de la clase \circ y un prototipo excluido \mathbf{y} de la clase \bullet resulta en:

$$d(\bullet, \circ) = \sqrt{\frac{1}{\sigma_{1\circ}^2} (y_1 - p_1)^2 + \frac{1}{\sigma_{2\circ}^2} (y_2 - p_2)^2} = \sqrt{\frac{1}{\alpha} (y_1 - p_1)^2 + \frac{1}{0} (y_2 - p_2)^2} = +\infty$$

Lo mismo ocurre cuando calculamos la distancia Mahalanobis-diagonal por clase entre un prototipo \mathbf{p} de la clase \bullet y un prototipo excluido \mathbf{y} de la clase \circ . Sin embargo, no ocurre lo mismo cuando calculamos esta distancia entre prototipos de la misma clase. Por ejemplo, para dos prototipos de la clase \circ :

$$d(\circ, \circ) = \sqrt{\frac{1}{\sigma_{1\circ}^2} (y_1 - p_1)^2 + \frac{1}{\sigma_{2\circ}^2} (y_2 - p_2)^2} = \sqrt{\frac{1}{\alpha} (y_1 - p_1)^2 + \frac{1}{0} (0)^2} = \sqrt{\frac{1}{\alpha} (y_1 - p_1)^2}$$

Por tanto, todos los prototipos son correctamente clasificados y el algoritmo de Wilson no elimina ninguno.

2. (1 punto) Dados los parámetros de un clasificador multinomial $\hat{\mathbf{p}}_1 = (0.5 \ 0.3 \ 0.2 \ 0.0 \ 0.0)$ y $\hat{\mathbf{p}}_2 = (0.0 \ 0.0 \ 0.3 \ 0.3 \ 0.4)$ con priors idénticas, clasifica la muestra de test $y = (1 \ 1 \ 1 \ 1 \ 1)$ tras aplicar los siguientes suavizados:

- a) Laplace con $\epsilon = 0.1$
b) Descuento absoluto con $\epsilon = 0.05$ y backing-off utilizando como distribución generalizada, la distribución uniforme.

Solución:

a)

$$\hat{\mathbf{p}}_1 = \begin{pmatrix} 0.5 \\ 0.3 \\ 0.2 \\ 0.0 \\ 0.0 \end{pmatrix} \rightarrow \hat{\mathbf{p}}_1 = \frac{1}{1.5} \begin{pmatrix} 0.5 + 0.1 \\ 0.3 + 0.1 \\ 0.2 + 0.1 \\ 0.0 + 0.1 \\ 0.0 + 0.1 \end{pmatrix} = \frac{1}{1.5} \begin{pmatrix} 0.6 \\ 0.4 \\ 0.3 \\ 0.1 \\ 0.1 \end{pmatrix}$$

$$\hat{\mathbf{p}}_2 = \begin{pmatrix} 0.0 \\ 0.0 \\ 0.3 \\ 0.3 \\ 0.4 \end{pmatrix} \rightarrow \hat{\mathbf{p}}_2 = \frac{1}{1.5} \begin{pmatrix} 0.0 + 0.1 \\ 0.0 + 0.1 \\ 0.3 + 0.1 \\ 0.3 + 0.1 \\ 0.4 + 0.1 \end{pmatrix} = \frac{1}{1.5} \begin{pmatrix} 0.1 \\ 0.1 \\ 0.4 \\ 0.4 \\ 0.5 \end{pmatrix}$$

En nuestro caso, dado que las priors son idénticas, la regla de clasificación se reduce a: $\hat{c}(y) = \arg \max_c p(y \mid c)$

$$p(y = (1 \ 1 \ 1 \ 1 \ 1) \mid c = 1) = \frac{0.6}{1.5} \cdot \frac{0.4}{1.5} \cdot \frac{0.3}{1.5} \cdot \frac{0.1}{1.5} \cdot \frac{0.1}{1.5} = 0.00009$$

$$p(y = (1 \ 1 \ 1 \ 1 \ 1) \mid c = 2) = \frac{0.1}{1.5} \cdot \frac{0.1}{1.5} \cdot \frac{0.4}{1.5} \cdot \frac{0.4}{1.5} \cdot \frac{0.5}{1.5} = 0.0001$$

La muestra y se clasifica en la clase 2.

b)

$$\hat{\mathbf{p}}_1 = \begin{pmatrix} 0.5 \\ 0.3 \\ 0.2 \\ 0.0 \\ 0.0 \end{pmatrix} \rightarrow \hat{\mathbf{p}}_1 = \begin{pmatrix} 0.5 - 0.05 \\ 0.3 - 0.05 \\ 0.2 - 0.05 \\ 0.0 + \frac{1}{2} \cdot 0.15 \\ 0.0 + \frac{1}{2} \cdot 0.15 \end{pmatrix} = \begin{pmatrix} 0.45 \\ 0.25 \\ 0.15 \\ 0.075 \\ 0.075 \end{pmatrix}$$

$$\hat{\mathbf{p}}_2 = \begin{pmatrix} 0.0 \\ 0.0 \\ 0.3 \\ 0.3 \\ 0.4 \end{pmatrix} \rightarrow \hat{\mathbf{p}}_2 = \begin{pmatrix} 0.0 + \frac{1}{2} \cdot 0.15 \\ 0.0 + \frac{1}{2} \cdot 0.15 \\ 0.3 - 0.05 \\ 0.3 - 0.05 \\ 0.4 - 0.05 \end{pmatrix} = \begin{pmatrix} 0.075 \\ 0.075 \\ 0.25 \\ 0.25 \\ 0.35 \end{pmatrix}$$

$$p(y = (1 \ 1 \ 1 \ 1 \ 1) \mid c = 1) = 0.45 \cdot 0.25 \cdot 0.15 \cdot 0.075 \cdot 0.075 = 0.00009$$

$$p(y = (1 \ 1 \ 1 \ 1 \ 1) \mid c = 2) = 0.075 \cdot 0.075 \cdot 0.25 \cdot 0.25 \cdot 0.35 = 0.0001$$

La muestra y se clasifica en la clase 2.

3. (1 punto) Sea la mixtura de gaussianas dada por las siguientes dos distribuciones gaussianas y sus correspondientes pesos:

$$\mathcal{N}_1(w_1, \mu_1, \Sigma_1) \quad \mu_1 = (2 \ 4)^t \quad \Sigma_1 = \begin{pmatrix} 1 & 0 \\ 0 & 4 \end{pmatrix} \quad w_1 = \frac{1}{3}$$

$$\mathcal{N}_2(w_2, \mu_2, \Sigma_2) \quad \mu_2 = (5 \ -1)^t \quad \Sigma_2 = \begin{pmatrix} \frac{9}{2} & 0 \\ 0 & 2 \end{pmatrix} \quad w_2 = \frac{2}{3}$$

Obtener la probabilidad de que la mixtura genere el dato $x = (3 \ 0)^t$.

Solución:

$$p(x|\mathcal{N}_1) = \frac{1}{|\Sigma_1|^{\frac{1}{2}}(2\pi)^{\frac{d}{2}}} e^{-\frac{1}{2}(x-\mu_1)^t \Sigma_1^{-1}(x-\mu_1)} = \frac{1}{2 \cdot (2\pi)} e^{-\frac{1}{2}(1 \ -4) \begin{pmatrix} 1 & 0 \\ 0 & \frac{1}{4} \end{pmatrix} (1 \ -4)^t} = \frac{1}{4\pi} e^{-\frac{1}{2}(1 \ -1)(1 \ -4)^t} = \frac{1}{4\pi} e^{-\frac{5}{2}}$$

$$p(x|\mathcal{N}_2) = \frac{1}{|\Sigma_2|^{\frac{1}{2}}(2\pi)^{\frac{d}{2}}} e^{-\frac{1}{2}(x-\mu_2)^t \Sigma_2^{-1}(x-\mu_2)} = \frac{1}{3 \cdot (2\pi)} e^{-\frac{1}{2}(-2 \ 1) \begin{pmatrix} \frac{2}{9} & 0 \\ 0 & \frac{1}{2} \end{pmatrix} (-2 \ 1)^t} = \frac{1}{6\pi} e^{-\frac{1}{2}(-\frac{4}{9} \ \frac{1}{2})(-2 \ 1)^t} =$$

$$\frac{1}{6\pi} e^{-\frac{1}{2} \frac{25}{18}} = \frac{1}{6\pi} e^{-\frac{25}{36}}$$

$$p(x|\{\mathcal{N}_1, \mathcal{N}_2\}) = w_1 \cdot p(x|\mathcal{N}_1) + w_2 \cdot p(x|\mathcal{N}_2) = \frac{1}{3} \cdot \frac{1}{4\pi} e^{-\frac{5}{2}} + \frac{2}{3} \cdot \frac{1}{6\pi} e^{-\frac{25}{36}} = \frac{1}{12\pi} e^{-\frac{5}{2}} + \frac{1}{9\pi} e^{-\frac{25}{36}} \approx$$

$$0.0022 + 0.0177 = 0.0198$$

4. (1 punto) Sea la siguiente función kernel, $K(x, y) = (x \cdot y + 1)^d$, con $d = 2$. Sea el siguiente conjunto de aprendizaje $X = \{(x_1, +1), (x_2, +1), (x_3, +1), (x_4, -1), (x_5, -1)\}$, con: $x_1 = (1, 1)$, $x_2 = (1, 0)$, $x_3 = (0, 1)$, $x_4 = (2, 1)$, $x_5 = (1, 2)$. Se tienen los siguientes pesos α_i : $\alpha_1 = \alpha_2 = \alpha_3 = 1$, $\alpha_4 = \alpha_5 = 0.5$. Clasifica la muestra de test $y = (0, 2)$.

Solución:

$$\begin{aligned}
 g(y) &= \sum_{i=1}^n \alpha_i c_i K(y, x_i) + \sum_{i=1}^n \alpha_i c_i = \\
 &1 \cdot (+1) \cdot K(y, x_1) + 1 \cdot (+1) \cdot K(y, x_2) + 1 \cdot (+1) \cdot K(y, x_3) + (0.5) \cdot (-1) \cdot K(y, x_4) + (0.5) \cdot (-1) \cdot K(y, x_5) \\
 &+ 1 \cdot (+1) + 1 \cdot (+1) + 1 \cdot (+1) + (0.5) \cdot (-1) + (0.5) \cdot (-1) = \\
 &(+1) \cdot 9 + (+1) \cdot 1 + (+1) \cdot 9 + (-0.5) \cdot 9 + (-0.5) \cdot 25 + (+1) + (+1) + (+1) + (-0.5) + (-0.5) = 19 - 17 + 2 = 4
 \end{aligned}$$

Por tanto, al ser $g(x) > 0$, se clasifica en $+1$.