

Examen de Teoría de Percepción - Recuperación Segundo Parcial

ETSINF, Universitat Politècnica de València, Junio de 2017

Apellidos:

Nombre:

Profesor: ☐ Jorge Civera ☐ Carlos Martínez

Cuestiones (2 puntos, 30 minutos, sin apuntes)

A Se define la función kernel $K(\mathbf{x}, \mathbf{y}) = \frac{1}{d(\mathbf{x}, \mathbf{y})+1}$ siendo $d(\mathbf{x}, \mathbf{y})$ la distancia de Hamming ($d(\mathbf{x}, \mathbf{y}) = \sum_{i=1}^D 1 - \delta(x_i, y_i)$), ¿cuál de las siguientes funciones **no** es un kernel?

- A) $K(\mathbf{x}, \mathbf{y}) = d(\mathbf{x}, \mathbf{y}) + 1$
- B) $K(\mathbf{x}, \mathbf{y}) = \frac{1}{d(\mathbf{x}, \mathbf{y})+1} + 1$
- C) $K(\mathbf{x}, \mathbf{y}) = e^{\frac{1}{d(\mathbf{x}, \mathbf{y})+1}}$
- D) $K(\mathbf{x}, \mathbf{y}) = \frac{1}{2 \cdot d(\mathbf{x}, \mathbf{y})+2}$

B Sea el conjunto de datos:

x_1	0	1	1	0	0	1	1	1	1	0
x_2	0	0	0	1	0	1	0	0	1	1
x_3	1	1	0	0	1	0	0	0	1	0
c	A	A	A	A	A	B	B	B	B	B

Indica la estimación por máxima verosimilitud de los parámetros de las distribuciones de Bernoulli para las clases A y B con ese conjunto de datos.

- A) $\mathbf{p}_A = \left(\frac{3}{5} \frac{4}{5} \frac{2}{5}\right), \mathbf{p}_B = \left(\frac{4}{5} \frac{3}{5} \frac{1}{5}\right)$
- B) $\mathbf{p}_A = \left(\frac{2}{5} \frac{1}{5} \frac{3}{5}\right), \mathbf{p}_B = \left(\frac{4}{5} \frac{3}{5} \frac{1}{5}\right)$
- C) $\mathbf{p}_A = \left(\frac{2}{5} \frac{1}{5} \frac{3}{5}\right), \mathbf{p}_B = \left(\frac{1}{5} \frac{2}{5} \frac{4}{5}\right)$
- D) $\mathbf{p}_A = \left(\frac{7}{15} \frac{7}{15} \frac{7}{15}\right), \mathbf{p}_B = \left(\frac{8}{15} \frac{8}{15} \frac{8}{15}\right)$

C Dados el prototipo multinomial $\hat{p} = (0.3 \ 0.0 \ 0.4 \ 0.0 \ 0.5)^t$ estimado a partir de un conjunto de vectores de cuentas, y su correspondiente prototipo multinomial suavizado $\tilde{p} = (0.2 \ 0.15 \ 0.3 \ 0.15 \ 0.4)^t$. ¿Qué tipo de suavizado ha sido aplicado?

- A) Laplace con $\epsilon = 0.1$
- B) Laplace con $\epsilon = 0.2$
- C) Descuento absoluto con $\epsilon = 0.1$ aplicando backing-off con distribución uniforme
- D) Descuento absoluto con $\epsilon = 0.1$ aplicando interpolación con distribución uniforme

D ¿Cuál de las siguientes expresiones representa un clasificador basado en el vecino más cercano?

- A) $\hat{c}(y) = \arg \min_c \max_{\mathbf{x} \in X_c} d(\mathbf{x}, \mathbf{y})$
- B) $\hat{c}(y) = \arg \max_c \max_{\mathbf{x} \in X_c} d(\mathbf{x}, \mathbf{y})$
- C) $\hat{c}(y) = \arg \max_c \min_{\mathbf{x} \in X_c} d(\mathbf{x}, \mathbf{y})$
- D) $\hat{c}(y) = \arg \min_c \min_{\mathbf{x} \in X_c} d(\mathbf{x}, \mathbf{y})$

B A diferencia de los clasificadores basados en Bayes, el clasificador k -NN:

- A) Sólo puede aplicarse a datos no vectoriales.
- B) Estima directamente $\hat{P}(c|x)$.
- C) Alcanza una cota de error inferior a Bayes.
- D) Crea un modelo basado en inferencia sobre los prototipos.

D Para que el clasificador k -NN alcance el error de Bayes, siendo n el número de prototipos:

- A) Debe usar un valor n potencialmente infinito, independientemente del k usado.
- B) Debe usar un valor k potencialmente infinito, independientemente de n .
- C) Debe usar un valores k y n potencialmente infinitos, con relación constante entre ellos.
- D) Debe usar un valores k y n potencialmente infinitos, pero con k de crecimiento mucho más lento que n .

A La distancia de Mahalanobis-diagonal:

- A) Equivale a prenormalizar cada componente por la desviación típica y usar distancia euclídea.
- B) Asigna pesos distintos por cada prototipo considerado.
- C) Usa las varianzas por clase.
- D) Incrementa la medida de distancia para las componentes que presentan una mayor dispersión.

C En general, ¿cuál de las siguientes enumeraciones de clasificadores está ordenada de mayor a menor *variance* (de izquierda a derecha)?

- A) k -NN, Multinomial, Gaussiano
- B) Gaussiano, k -NN, Multinomial
- C) k -NN, Gaussiano, Multinomial
- D) Gaussiano, Multinomial, k -NN

Examen de Teoría de Percepción - Recuperación Segundo Parcial

ETSINF, Universitat Politècnica de València, Junio de 2017

Apellidos:

Nombre:

Profesor: ☐ Jorge Civera ☐ Carlos Martínez

Problemas (4 puntos, 90 minutos, con apuntes)

1. (1.5 puntos) Sea A y B dos clases con priors $p(A) = 1/4$ y $p(B) = 3/4$, y f.d.p. condicionales de clase gaussianas $p(\mathbf{x} | A) \sim N_2(\mu_A, \Sigma_A)$ y $p(\mathbf{x} | B) \sim N_2(\mu_B, \Sigma_B)$

$$\mu_A = \begin{pmatrix} 0 \\ 0 \end{pmatrix} \quad \Sigma_A = \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix} \quad \mu_B = \begin{pmatrix} 1 \\ 1 \end{pmatrix} \quad \Sigma_B = \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix}$$

- a) Calcula funciones discriminantes para A y B . (0.5 puntos)
b) Calcula la frontera de decisión entre las clases A y B . (0.5 puntos)
c) Representa gráficamente la frontera y las regiones de decisión. (0.5 puntos)

Solución:

- a) En el caso de matrices de covarianza común, la función discriminante se define como:

$$g_c(\mathbf{x}) = \mathbf{w}_c^t \mathbf{x} + b_c$$

donde

$$\mathbf{w}_c = \Sigma^{-1} \mu_c \quad b_c = \log P(c) - \frac{1}{2} \mu_c^t \Sigma^{-1} \mu_c$$

Las funciones discriminantes de las clases serían:

$$g_A(\mathbf{x}) = \mathbf{w}_A^t \mathbf{x} + b_A$$

$$\mathbf{w}_A = \Sigma^{-1} \mu_A = \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix}^{-1} \begin{pmatrix} 0 \\ 0 \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \end{pmatrix}$$

$$b_A = \log P(A) - \frac{1}{2} \mu_A^t \Sigma^{-1} \mu_A = \log \frac{1}{4} - \frac{1}{2} \begin{pmatrix} 0 \\ 0 \end{pmatrix}^t \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix}^{-1} \begin{pmatrix} 0 \\ 0 \end{pmatrix} = -\log 4$$

$$g_A(\mathbf{x}) = \begin{pmatrix} 0 \\ 0 \end{pmatrix}^t \begin{pmatrix} x_1 \\ x_2 \end{pmatrix} - \log 4 = -\log 4$$

$$g_B(\mathbf{x}) = \mathbf{w}_B^t \mathbf{x} + b_B$$

$$\mathbf{w}_B = \Sigma^{-1} \mu_B = \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix}^{-1} \begin{pmatrix} 1 \\ 1 \end{pmatrix} = \begin{pmatrix} 1 \\ 1 \end{pmatrix}$$

$$b_B = \log P(B) - \frac{1}{2} \mu_B^t \Sigma^{-1} \mu_B = \log \frac{3}{4} - \frac{1}{2} \begin{pmatrix} 1 \\ 1 \end{pmatrix}^t \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix}^{-1} \begin{pmatrix} 1 \\ 1 \end{pmatrix} = \log \frac{3}{4} - 1$$

$$g_B(\mathbf{x}) = \begin{pmatrix} 1 \\ 1 \end{pmatrix}^t \begin{pmatrix} x_1 \\ x_2 \end{pmatrix} + \log \frac{3}{4} - 1 = x_1 + x_2 + \log 3 - \log 4 - 1$$

- b) La frontera de decisión entre las clases A y B se obtiene igualando sus respectivas funciones discriminantes

$$g_A(\mathbf{x}) = g_B(\mathbf{x})$$

Por tanto,


$$-\log 4 = x_1 + x_2 + \log 3 - \log 4 - 1$$

$$0 = x_1 + x_2 + \log 3 - 1$$

$$x_2 = -x_1 - \log 3 + 1 = -x_1 - 0.1$$

que es una frontera lineal.


c)



2. (1.5 puntos) Sea la función Kernel $K(\mathbf{x}, \mathbf{y}) = \frac{1}{d(\mathbf{x}, \mathbf{y}) + 1}$ siendo $d(\mathbf{x}, \mathbf{y})$ la distancia de Hamming ($d(\mathbf{x}, \mathbf{y}) = \sum_{i=1}^D 1 - \delta(x_i, y_i)$). Sea el conjunto de entrenamiento $\mathbf{x}_1 = (0, 0)$, $\mathbf{x}_2 = (0, 1)$, $\mathbf{x}_3 = (1, 0)$, $\mathbf{x}_4 = (1, 1)$, siendo $\mathbf{x}_1, \mathbf{x}_4 \in +1$ y $\mathbf{x}_2, \mathbf{x}_3 \in -1$.
- Representa gráficamente el conjunto de entrenamiento y di si es o no linealmente separable. (0.25 puntos)
 - Aplica una iteración de Kernel Perceptron partiendo de $\alpha = (0, 0, 0, 0)$, indicando el valor final de α . (0.75 puntos)
 - ¿Cuál es el error de clasificación de la función $g(x)$ resultante del apartado anterior sobre el conjunto de entrenamiento? (0.5 puntos)

Solución:

- a) Como se puede observar en la figura el conjunto de entrenamiento no es linealmente separable.



- b) La matriz de Gramm sobre el conjunto de entrenamiento para la función Kernel definida en el enunciado es

$$\mathbf{K} = \begin{matrix} & \begin{matrix} (0, 0) & (0, 1) & (1, 0) & (1, 1) \end{matrix} \\ \begin{matrix} (0, 0) \\ (0, 1) \\ (1, 0) \\ (1, 1) \end{matrix} & \begin{matrix} 1 & 1/2 & 1/2 & 1/3 \\ 1/2 & 1 & 1/2 & 1/2 \\ 1/2 & 1/2 & 1 & 1/2 \\ 1/3 & 1/2 & 1/2 & 1 \end{matrix} \end{matrix}$$

La traza del algoritmo Kernel Perceptron es la siguiente:

	$g(x)$	$g(x_i)$	c_i	error	α
x_1	0	0	+1	Sí	(1, 0, 0, 0)
x_2	$K(x_1, x) + 1$	3/2	-1	Sí	(1, 1, 0, 0)
x_3	$K(x_1, x) + 1 - K(x_2, x) - 1$	0	-1	Sí	(1, 1, 1, 0)
x_4	$K(x_1, x) + 1 - K(x_2, x) - 1 - K(x_3, x) - 1$	-5/6	+1	Sí	(1, 1, 1, 1)

c) Considerando el vector de pesos $\alpha = (1, 1, 1, 1)$ obtenidos, la función discriminante es:

$$g(x) = K(x_1, x) + 1 - K(x_2, x) - 1 - K(x_3, x) - 1 + K(x_4, x) + 1 \\ = K(x_1, x) - K(x_2, x) - K(x_3, x) + K(x_4, x)$$

	$g(x_i)$					c_i	error
x_1	1	-1/2	-1/2	+1/3	=	1/3	+1 No
x_2	1/2	-1	-1/2	+1/2	=	-1/2	-1 No
x_3	1/2	-1/2	-1	+1/2	=	-1/2	-1 No
x_4	1/3	-1/2	-1/2	+1	=	1/3	+1 No

Por tanto, el error de clasificación es cero y la función Kernel empleada proyecta el conjunto de entrenamiento a un espacio donde son linealmente separables.

3. (1 punto) Sean las siguientes muestras y clasificadores:

$$\mathbf{x}_1 = (0, 0) \in +1 \quad \mathbf{x}_2 = (2, 2) \in -1 \quad \mathbf{x}_3 = (1, 2) \in +1 \quad \mathbf{x}_4 = (0, 1) \in -1 \quad \mathbf{x}_5 = (-1, 1) \in +1$$

$$g_1(\mathbf{z}) = \begin{cases} +1 & z_1 > 0 \\ -1 & z_1 \leq 0 \end{cases} \quad g_2(\mathbf{z}) = \begin{cases} +1 & z_2 > 1 \\ -1 & z_2 \leq 1 \end{cases} \quad g_3(\mathbf{z}) = \begin{cases} +1 & z_2 - z_1 > 0 \\ -1 & z_2 - z_1 \leq 0 \end{cases} \quad g_4(\mathbf{z}) = \begin{cases} +1 & z_1 + z_2 \leq 3 \\ -1 & z_1 + z_2 > 3 \end{cases}$$

Aplica una iteración de AdaBoost para ese conjunto de datos y clasificadores indicando:

- Clasificador escogido C_1 .
- Valor de ϵ_1 .
- Valor de α_1 .
- Actualización de los pesos para la siguiente iteración ($w^{(2)}$).

Solución:

Tabla de acierto/fallo:

	g_1	g_2	g_3	g_4
\mathbf{x}_1	X	X	X	✓
\mathbf{x}_2	X	X	✓	✓
\mathbf{x}_3	✓	✓	✓	✓
\mathbf{x}_4	✓	✓	X	X
\mathbf{x}_5	X	X	✓	✓

Pesos iniciales: $w^{(1)} = (\frac{1}{5}, \frac{1}{5}, \frac{1}{5}, \frac{1}{5}, \frac{1}{5})$

Sumatorio de los $w^{(1)}$ de las muestras incorrectas:

g_1	g_2	g_3	g_4
$\frac{3}{5}$	$\frac{3}{5}$	$\frac{2}{5}$	$\frac{1}{5}$

$$C_1 = g_4 \\ \epsilon_1 = \frac{1}{5} \\ \alpha_1 = \frac{1}{2} \ln 4 = \ln 2$$

	$w^{(1)} \exp(-y_i \alpha_1 C_1(x_i))$
\mathbf{x}_1	$\frac{1}{10}$
\mathbf{x}_2	$\frac{1}{10}$
\mathbf{x}_3	$\frac{1}{10}$
\mathbf{x}_4	$\frac{2}{5} = \frac{4}{10}$
\mathbf{x}_5	$\frac{1}{10}$
Suma total	$\frac{4}{5} = \frac{8}{10}$

$$w^{(2)} = (\frac{1}{8}, \frac{1}{8}, \frac{1}{8}, \frac{1}{2}, \frac{1}{8})$$