



UNIVERSITAT
POLITÈCNICA
DE VALÈNCIA

Escola Tècnica Superior d'Enginyeria Informàtica



Tema 6. Distribución Multinomial

Percepción (PER)

Curso 2017/2018

Departamento de Sistemas Informáticos y Computación

Índice

- 1 Introducción y motivación ▷ 3
- 2 Definición de la distribución multinomial ▷ 5
- 3 Clasificador multinomial ▷ 9
- 4 Entrenamiento por máxima verosimilitud (MV) ▷ 12
- 5 Suavizado ▷ 14

Índice

- 1 *Introducción y motivación* ▷ 3
- 2 Definición de la distribución multinomial ▷ 5
- 3 Clasificador multinomial ▷ 9
- 4 Entrenamiento por máxima verosimilitud (MV) ▷ 12
- 5 Suavizado ▷ 14

Distribución multinomial: motivación

Algunas tareas de RF representan objetos como *vectores de cuentas*

Ejemplo: Texto representado como *bag-of-words*

3 mensajes enviados a alt.atheism	0	0	0	windows
	4	11	3	god
	0	0	0	dod
	0	3	0	government
	2	0	1	writes
	14	7	15	people
	0	0	0	team
	0	0	0	bike
	0	0	0	game
	0	3	0	car
	0	1	0	article
	0	0	0	hockey
	0	0	0	rutgers
	0	0	0	encryption
	0	0	0	israel
	4	1	3	jesus
	0	0	0	clipper
	1	2	11	christians
	8	8	0	bible
	7	4	3	christian
⇒				
3 mensajes enviados a comp.windows.x	17	17	9	windows
	0	0	0	god
	0	0	0	dod
	0	0	0	government
	0	1	0	writes
	4	3	5	people
	1	0	0	team
	0	0	0	bike
	0	1	0	game
	0	0	0	car
	3	0	8	article
	0	0	0	hockey
	0	0	0	rutgers
	0	0	0	encryption
	0	0	0	israel
	0	0	0	jesus
	0	0	0	clipper
	0	0	0	christians
	2	0	0	bible
	0	1	0	christian
⇒				
3 mensajes enviados a rec.sport.hockey	0	0	0	windows
	0	0	0	god
	0	0	0	dod
	1	0	0	government
	0	0	2	writes
	8	0	7	people
	9	10	0	team
	0	0	0	bike
	3	13	10	game
	0	0	0	car
	0	0	0	article
	8	2	5	hockey
	0	0	0	rutgers
	0	0	0	encryption
	0	0	0	israel
	0	0	0	jesus
	0	0	0	clipper
	0	0	0	christians
	0	0	0	bible
	0	0	0	christian

Idea: usar la *distribución multinomial* para modelizar la condicional $p(\mathbf{x}|\mathbf{c})$

Índice

- 1 Introducción y motivación ▷ 3
- 2 *Definición de la distribución multinomial* ▷ 5
- 3 Clasificador multinomial ▷ 9
- 4 Entrenamiento por máxima verosimilitud (MV) ▷ 12
- 5 Suavizado ▷ 14

Definición: distribución multinomial

Sea una población $\mathcal{Y} = \{y_1, \dots, y_n\}$ con $y_i \in \{1, \dots, D\}$,

Sean las proporciones p_d de los tipos de elemento $\{1, \dots, D\}$ dadas por:

$$\mathbf{p} = (p_1, \dots, p_D)^t \in [0, 1]^D \quad \text{con} \quad \sum_{d=1}^D p_d = 1$$

Sea una secuencia de N elementos formada por extracción aleatoria con reemplazo desde \mathcal{Y}

$$w_1^N = w_1 w_2 \cdots w_N$$

Número de secuencias distintas de longitud N :

$$\text{VR}_{D,N} = D^N$$

Definición: distribución multinomial

Asumiendo independencia entre elementos:

$$p(w_1^N) = p_{w_1} p_{w_2} \cdots p_{w_N}$$

No depende del orden de los elementos, sino de su número de ocurrencias:

- x_d : el número de ocurrencias del elemento d en w_1^N
- $\mathbf{x} = (x_1, \dots, x_D)^t$: vector de ocurrencias (número de ocurrencias de cada elemento en w_1^N)

$$p(w_1^N) = p_1^{x_1} \cdots p_D^{x_D} = \prod_{d=1}^D p_d^{x_d}$$

El número de secuencias diferentes con el mismo vector de ocurrencias es un *coeficiente multinomial*:

$$\binom{N}{\mathbf{x}} = \binom{N}{x_1, \dots, x_D} = \frac{N!}{x_1! \cdots x_D!}$$

Definición: distribución multinomial

Distribución multinomial: se define sobre el espacio de vectores de ocurrencias

La probabilidad de \mathbf{x} es la suma de probabilidades de todas las secuencias con vector de ocurrencias \mathbf{x} :

$$p(\mathbf{x}) = \binom{N}{\mathbf{x}} \prod_{d=1}^D p_d^{x_d}$$

$p(\mathbf{x})$ es una f.d. multinomial:

- D -dimensional
- Longitud $N = \sum_{d=1}^D x_d$
- Prototipo \mathbf{p}

De ahora en adelante, usaremos $x_+ = N$.

Índice

- 1 Introducción y motivación ▷ 3
- 2 Definición de la distribución multinomial ▷ 5
- 3 *Clasificador multinomial* ▷ 9
- 4 Entrenamiento por máxima verosimilitud (MV) ▷ 12
- 5 Suavizado ▷ 14

Clasificador multinomial

Clasificador multinomial: clasificador de Bayes donde la f.d. condicional $p(\mathbf{x}|c)$ es una multinomial

$$p(\mathbf{x} | c) \sim \text{Mult}_D(x_+, \mathbf{p}_c), \quad c = 1, \dots, C.$$

Por tanto:

$$\begin{aligned} c^*(\mathbf{x}) &= \operatorname{argmax}_{c=1, \dots, C} \log P(c) + \log p(\mathbf{x} | c) \\ &= \operatorname{argmax}_{c=1, \dots, C} \log P(c) + \log \frac{x_+!}{x_1! \cdots x_D!} \prod_{d=1}^D p_{cd}^{x_d} \\ &= \operatorname{argmax}_{c=1, \dots, C} \log P(c) + \log \frac{x_+!}{x_1! \cdots x_D!} + \sum_{d=1}^D x_d \log p_{cd} \end{aligned}$$

Clasificador multinomial

Eliminando el término independiente de c :

$$c^*(\mathbf{x}) = \operatorname{argmax}_{c=1,\dots,C} \log P(c) + \sum_{d=1}^D x_d \log p_{cd}$$

Expresando el sumatorio en forma de producto escalar:

$$c^*(\mathbf{x}) = \operatorname{argmax}_{c=1,\dots,C} (\log \mathbf{p}_c)^t \mathbf{x} + \log P(c)$$

En forma de clasificador lineal:

$$c^*(\mathbf{x}) = \operatorname{argmax}_{c=1,\dots,C} g_c(\mathbf{x}) = \operatorname{argmax}_{c=1,\dots,C} \mathbf{w}_c^t \mathbf{x} + w_{c0}$$

Con:

$$\mathbf{w}_c = \log \mathbf{p}_c \quad w_{c0} = \log P(c)$$

Índice

- 1 Introducción y motivación ▷ 3
- 2 Definición de la distribución multinomial ▷ 5
- 3 Clasificador multinomial ▷ 9
- 4 *Entrenamiento por máxima verosimilitud (MV)* ▷ 12
- 5 Suavizado ▷ 14

Entrenamiento por máxima verosimilitud

Sean N muestras de entrenamiento aleatoriamente extraídas de C distribuciones multinomiales independientes:

$$\{(\mathbf{x}_n, c_n)\}_{n=1}^N \text{ i.i.d. } p(\mathbf{x}, c) = P(c) p(\mathbf{x}|c), \quad p(\mathbf{x}|c) \sim \text{Mult}_D(x_+, \mathbf{p}_c)$$

Conjunto de parámetros a estimar Θ :

- Probabilidades *a priori*: $P(1) \dots, P(C)$
- Prototipos de las multinomiales para cada clase c : $\mathbf{p}_c, c = 1, \dots, C$

Por ***criterio de máxima verosimilitud*** (MV), se estima Θ como:

$$\hat{P}(c) = \frac{N_c}{N} \quad \hat{\mathbf{p}}_c = \frac{1}{\sum_{n: c_n=c} \sum_{d=1}^D x_{nd}} \sum_{n: c_n=c} \mathbf{x}_n \quad c = 1, \dots, C$$

Índice

- 1 Introducción y motivación ▷ 3
- 2 Definición de la distribución multinomial ▷ 5
- 3 Clasificador multinomial ▷ 9
- 4 Entrenamiento por máxima verosimilitud (MV) ▷ 12
- 5 *Suavizado* ▷ 14

Suavizado de la distribución multinomial

Laplace: suma una constante $\epsilon > 0$ a cada parámetro y renormaliza

Descuento Absoluto (DA):

1. Descuenta una constante $\epsilon > 0$ (pequeña) a cada parámetro mayor que cero
2. Distribuir la probabilidad descontada según una *distribución generalizada*:
 - Entre todos los parámetros nulos (*backing-off*)
 - Entre todos los parámetros (*interpolación*)

