



UNIVERSITAT
POLITÈCNICA
DE VALÈNCIA

Escola Tècnica Superior d'Enginyeria Informàtica



Tema 7. Distribución Gaussiana

Percepción (PER)

Curso 2017/2018

Departamento de Sistemas Informáticos y Computación

Índice

- 1 Introducción y motivación ▷ 3
- 2 Definición de la distribución gaussiana ▷ 5
- 3 Clasificador gaussiano ▷ 9
- 4 Entrenamiento por máxima verosimilitud (MV) ▷ 13
- 5 Suavizado ▷ 16


Índice

- 1 *Introducción y motivación* ▷ 3
- 2 Definición de la distribución gaussiana ▷ 5
- 3 Clasificador gaussiano ▷ 9
- 4 Entrenamiento por máxima verosimilitud (MV) ▷ 13
- 5 Suavizado ▷ 16

Introducción y motivación

Algunas tareas representan objetos por *vectores de características reales* (\mathbb{R}^D)

Ejemplo: Imágenes de 5×5 en escala de grises interpretadas como vectores reales de características de 25 dimensiones.



Ejemplo: Señal acústica mediante vectores de coeficientes cepstrales

Idea: usar la *distribución gaussiana* para modelizar la condicional $p(\mathbf{x}|c)$

Índice

- 1 Introducción y motivación ▷ 3
- 2 *Definición de la distribución gaussiana* ▷ 5
- 3 Clasificador gaussiano ▷ 9
- 4 Entrenamiento por máxima verosimilitud (MV) ▷ 13
- 5 Suavizado ▷ 16

Definición: distribución gaussiana unidimensional

Sea x una variable aleatoria unidimensional

Gaussiana unidimensional estandarizada

$x \sim N(0, 1)$ presenta una distribución de probabilidad

$$p(x) = \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{1}{2}x^2\right)$$

Gaussiana unidimensional general

$x \sim N(\mu, \sigma)$, con media $\mu \in \mathbb{R}$ y varianza $\sigma^2 \in \mathbb{R}^+$, presenta una distribución de probabilidad

$$p(x) = \frac{1}{\sigma\sqrt{2\pi}} \exp\left(-\frac{1}{2}\left(\frac{x - \mu}{\sigma}\right)^2\right)$$

Definición: distribución gaussiana multidimensional

Sea $\mathbf{x} = (x_1, \dots, x_D)^t$ una variable aleatoria D -dimensional

Gaussiana estandarizada

$\mathbf{x} \sim N_D(\mathbf{0}, I_D)$, donde $x_1, \dots, x_D \sim N(0, 1)$ independientes, presenta una distribución de probabilidad:

$$p(\mathbf{x}) = (2\pi)^{-\frac{D}{2}} \exp\left(-\frac{1}{2} \mathbf{x}^t \mathbf{x}\right)$$

Definición: distribución gaussiana multidimensional

Gaussiana general

Sean:

- $\mathbf{z} \sim N_D(\mathbf{0}, I_D)$
- $\boldsymbol{\mu} \in \mathbb{R}^D$
- $A \in \mathbb{R}^{D \times D} : |A| \neq 0$
- $\Sigma = AA^t$ (simétrica y definida positiva) con:
 - $A = W\Delta^{\frac{1}{2}}$
 - W vectores propios de Σ
 - Δ valores propios de Σ
- $\mathbf{x} = A\mathbf{z} + \boldsymbol{\mu}$

$\mathbf{x} \sim N_D(\boldsymbol{\mu}, \Sigma)$, con media $\boldsymbol{\mu}$ y matriz de covarianzas Σ , presenta una distribución de probabilidad:

$$p(\mathbf{x}) = (2\pi)^{-\frac{D}{2}} |\Sigma|^{-\frac{1}{2}} \exp \left(-\frac{1}{2} (\mathbf{x} - \boldsymbol{\mu})^t \Sigma^{-1} (\mathbf{x} - \boldsymbol{\mu}) \right)$$

Índice

- 1 Introducción y motivación ▷ 3
- 2 Definición de la distribución gaussiana ▷ 5
- 3 *Clasificador gaussiano* ▷ 9
- 4 Entrenamiento por máxima verosimilitud (MV) ▷ 13
- 5 Suavizado ▷ 16

Clasificador gaussiano

Clasificador gaussiano: clasificador de Bayes donde la f.d. condicional $p(\mathbf{x}|c)$ es una gaussiana

$$p(\mathbf{x} | c) \sim N_D(\boldsymbol{\mu}_c, \Sigma_c), \quad c = 1, \dots, C.$$

Por tanto:

$$\begin{aligned} c^*(\mathbf{x}) &= \operatorname{argmax}_{c=1, \dots, C} \log P(c) + \log p(\mathbf{x} | c) \\ &= \operatorname{argmax}_{c=1, \dots, C} \log P(c) - \frac{D}{2} \log 2\pi - \frac{1}{2} \log |\Sigma_c| - \frac{1}{2} (\mathbf{x} - \boldsymbol{\mu}_c)^t \Sigma_c^{-1} (\mathbf{x} - \boldsymbol{\mu}_c) \\ &= \operatorname{argmax}_{c=1, \dots, C} \log P(c) - \frac{1}{2} \log |\Sigma_c| - \frac{1}{2} \mathbf{x}^t \Sigma_c^{-1} \mathbf{x} + \boldsymbol{\mu}_c^t \Sigma_c^{-1} \mathbf{x} - \frac{1}{2} \boldsymbol{\mu}_c^t \Sigma_c^{-1} \boldsymbol{\mu}_c \\ &= \operatorname{argmax}_{c=1, \dots, C} -\frac{1}{2} \mathbf{x}^t \Sigma_c^{-1} \mathbf{x} + \boldsymbol{\mu}_c^t \Sigma_c^{-1} \mathbf{x} + \left(\log P(c) - \frac{1}{2} \log |\Sigma_c| - \frac{1}{2} \boldsymbol{\mu}_c^t \Sigma_c^{-1} \boldsymbol{\mu}_c \right) \end{aligned}$$

Clasificador gaussiano

$$c^*(\mathbf{x}) = \operatorname{argmax}_{c=1,\dots,C} -\frac{1}{2}\mathbf{x}^t \Sigma_c^{-1} \mathbf{x} + \boldsymbol{\mu}_c^t \Sigma_c^{-1} \mathbf{x} + \left(\log P(c) - \frac{1}{2} \log |\Sigma_c| - \frac{1}{2} \boldsymbol{\mu}_c^t \Sigma_c^{-1} \boldsymbol{\mu}_c \right)$$

Clasificador *cuadrático* con \mathbf{x} :

$$c^*(\mathbf{x}) = \operatorname{argmax}_{c=1,\dots,C} g_c(\mathbf{x}) = \operatorname{argmax}_{c=1,\dots,C} \mathbf{x}^t W_c \mathbf{x} + \mathbf{w}_c^t \mathbf{x} + w_{c0}$$

Con:

$$W_c = -\frac{1}{2} \Sigma_c^{-1} \quad \mathbf{w}_c = \Sigma_c^{-1} \boldsymbol{\mu}_c$$

$$w_{c0} = \log P(c) - \frac{1}{2} \log |\Sigma_c| - \frac{1}{2} \boldsymbol{\mu}_c^t \Sigma_c^{-1} \boldsymbol{\mu}_c$$

Clasificador gaussiano

Caso particular: *matriz de covarianzas común*, $\Sigma_c = \Sigma$

En ese caso, tanto $-\frac{1}{2}\mathbf{x}^t\Sigma^{-1}\mathbf{x}$ como $-\frac{1}{2}\log|\Sigma|$ son independientes de c

$$c^*(\mathbf{x}) = \operatorname{argmax}_{c=1,\dots,C} \mu_c^t \Sigma^{-1} \mathbf{x} + \left(\log P(c) - \frac{1}{2} \mu_c^t \Sigma^{-1} \mu_c \right)$$

El clasificador gaussiano es *lineal*:

$$c^*(\mathbf{x}) = \operatorname{argmax}_{c=1,\dots,C} g_c(\mathbf{x}) = \operatorname{argmax}_{c=1,\dots,C} \mathbf{w}_c^t \mathbf{x} + w_{c0}$$

Con:

$$\mathbf{w}_c = \Sigma^{-1} \mu_c \quad w_{c0} = \log P(c) - \frac{1}{2} \mu_c^t \Sigma^{-1} \mu_c$$

Índice

- 1 Introducción y motivación ▷ 3
- 2 Definición de la distribución gaussiana ▷ 5
- 3 Clasificador gaussiano ▷ 9
- 4 *Entrenamiento por máxima verosimilitud (MV)* ▷ 13
- 5 Suavizado ▷ 16

Entrenamiento por máxima verosimilitud

Sean N muestras de entrenamiento aleatoriamente extraídas de C distribuciones gaussianas independientes

$$\{(\mathbf{x}_n, c_n)\}_{n=1}^N \quad \text{i.i.d.} \quad p(\mathbf{x}, c) = P(c) p(\mathbf{x}|c), \quad p(\mathbf{x}|c) \sim N_D(\boldsymbol{\mu}_c, \Sigma_c)$$

Conjunto de parámetros a estimar Θ :

- Probabilidades *a priori*: $P(1), \dots, P(C)$
- Medias para cada clase: μ_1, \dots, μ_C
- Matrices de covarianza para cada clase: $\Sigma_1, \dots, \Sigma_C$

Por ***criterio de máxima verosimilitud*** (MV), se estima Θ como:

$$\hat{P}(c) = \frac{N_c}{N} \quad (1)$$

$$\hat{\boldsymbol{\mu}}_c = \frac{1}{N_c} \sum_{n:c_n=c} \mathbf{x}_n \quad (2)$$

$$\hat{\Sigma}_c = \frac{1}{N_c} \sum_{n:c_n=c} (\mathbf{x}_n - \hat{\boldsymbol{\mu}}_c)(\mathbf{x}_n - \hat{\boldsymbol{\mu}}_c)^t = \left(\frac{1}{N_c} \sum_{n:c_n=c} \mathbf{x}_n \mathbf{x}_n^t \right) - \hat{\boldsymbol{\mu}}_c \hat{\boldsymbol{\mu}}_c^t \quad (3)$$

Entrenamiento por máxima verosimilitud

En el caso de Σ común para todas las clases ($\Sigma_c = \Sigma$), el conjunto de parámetros a estimar Θ es:

- Probabilidades *a priori*: $P(1), \dots, P(C)$
- Medias para cada clase: μ_1, \dots, μ_C
- Matriz de covarianza común: Σ

Por ***criterio de máxima verosimilitud***, la estimación de Θ se calcula como en el caso general (Ecuaciones (1) y (2) para $\hat{P}(c)$ y $\hat{\mu}_c$, respectivamente) y :

$$\hat{\Sigma} = \sum_c \hat{P}(c) \hat{\Sigma}_c = \frac{1}{N} \sum_n \mathbf{x}_n \mathbf{x}_n^t - \sum_c \hat{P}(c) \hat{\mu}_c \hat{\mu}_c^t \quad (4)$$

Con $\hat{\Sigma}_c$ calculada según Ecuación (3).

Índice

- 1 Introducción y motivación ▷ 3
- 2 Definición de la distribución gaussiana ▷ 5
- 3 Clasificador gaussiano ▷ 9
- 4 Entrenamiento por máxima verosimilitud (MV) ▷ 13
- 5 *Suavizado* ▷ 16

Suavizado

Umbralizado de covarianza [Duda01, pág. 113]

Covarianzas con magnitud de la correlación no cercana a uno valen cero:

$$\tilde{\sigma}_{cdd'}^2 = \begin{cases} \hat{\sigma}_{cdd'}^2 & \text{si } |\hat{\rho}_{cdd'}| > 1 - \epsilon \\ 0 & \text{otro caso} \end{cases} \quad \forall c, d, d' = 1, \dots, D; d \neq d'$$

Donde:

- ϵ es una constante pequeña no negativa ($\epsilon = 0 \rightarrow \Sigma$ diagonal)
- Coeficiente de correlación: $\hat{\rho}_{cdd'} = \frac{\hat{\sigma}_{cdd'}^2}{\hat{\sigma}_{cdd} \hat{\sigma}_{cd'd'}}$

Flat smoothing

Combinación lineal de cada $\hat{\Sigma}_c$ y $\tilde{\Sigma}$ (matriz de covarianza global suavizada):

$$\tilde{\Sigma}_c = \alpha \hat{\Sigma}_c + (1 - \alpha) \tilde{\Sigma} \quad \forall c \quad \alpha \in [0, 1]$$

Donde: $\tilde{\Sigma} = \beta \hat{\Sigma} + (1 - \beta)I, \beta \in [0, 1]$